


실무로 통하는 인과추론 with 파이썬

소프트웨어학과
202121052 이준형



CONTENTS

- 1 책 소개 및 발표 내용 소개
- 2 왜 인과추론인가?
- 3 머신러닝 VS 인과추론
- 4 인과추론의 근본적인 문제, 잠재적 결과
- 5 인과적 추정량
- 6 편향(Bias)
- 7 해결책: 무작위 통제 실험

01

책 소개

1. 저자 및 배경


- 저자: 마테우스 파쿠레 (데이터 과학자)
- 특징: 복잡한 통계 이론에 매몰되지 않고, '비즈니스 의사결정'에 어떻게 인과추론을 활용할 것인가라는 실천적 관점을 유지함.

2. 이 책의 핵심 질문

- "단순히 미래를 예측하는 것을 넘어, 우리의 개입이 어떤 결과를 가져올 것인가?"
- 데이터 속의 숨겨진 인과관계를 찾아내어 '최적화된 액션'을 도출하는 방법론 제시.

3. 주요 구성

- 이론: 잠재적 결과 모델, 그래프 모델 등 현대 인과 방법론의 핵심 정리.
- 실습: 파이썬 라이브러리를 활용한 실제 데이터 분석 구현.



01

발표 내용 소개

1부. 인과 추론의 기본 개념

1장. 가격 인하가 미치는 영향을 분석하는데 필요한 인과 추론의 주요 개념 소개

02

왜 인과 추론인가? (연관관계 vs 인과관계)

‘연관 관계는 인과관계가 아니다’



‘연관 관계는 때로 인과관계가 될 수도 있다’

연관관계 (Association)

두 변수 사이의 통계적 관련성,
한 변수의 값이 변할 때 다른 변수의 값도 함께 변하는 패턴을 보이는 상태

인과관계 (Causation)


한 변수의 변화가 다른 변수의 변화를 일으키는 직접적인 원인이 되는 관계

연관관계 (Association)

- "두 변수가 함께 움직인다."
- (예: 아이스크림 판매량과 햇볕으로 입은 화상)

인과관계 (Causation)

- "한 변수의 변화가 다른 변수의 변화를 일으킨다."
- (예: 기온 상승 → 아이스크림 판매량 증가 & 햇볕으로 입은 화상 증가)



*상관 관계는 예측에 유용하지만, 개입의 결과를 예측하려면 인과관계가 필요.

	store	weeks_to_xmas	avg_week_sales	is_on_sale	weekly_amount_sold
0	1	3	12.98	1	219.60
1	1	2	12.98	1	184.70
2	1	1	12.98	1	145.75
3	1	0	12.98	0	102.45
4	2	3	19.92	0	103.22
5	2	2	19.92	0	53.73

- store: 상점의 고유 식별자(ID)
- weeks_to_xmas: 크리스마스까지 남은 기간(주)
- avg_week_sales: 12월 각 상점의 주간 판매량
- is_on_sale: 해당 주간, 기업의 가격할인 진행 여부(진행 = 1, 미진행 = 0)
- weekly_amount_sold: 해당 연도의 상점 주간 평균 판매량

책에서 나온 예제 추가 필요

03

머신러닝 vs 인과추론

머신러닝 (Machine Learning)

vs

인과추론 (Casual Inference)

질문

“이 고객의 다음 달 매출 은 얼마인가?”

현재 상태에서의 수동적 관찰 및 결과 예측

“가격을 10% 낮추면 매출은 변하는가?”

특정 행동을 취했을 때의 능동적 개입 효과 추정

핵심

상관관계를 활용한 고도의 패턴 매칭

데이터 간의 연관성을 학습하여 결과 도출

'만약 ~한다면?'에 대한 반사실 탐구

관측되지 않은 잠재적 결과를 비교

목표

예측 정확도 극대화

오차 최소화

편향 없는 효과 추정

순수한 인과 효과 식별

*단순 예측을 넘어, 비즈니스 성과를 극대화하는 최적의 개입 정책 을 결정 가능

04

인과추론의 근본적인 문제와 잠재적 결과

잠재적 결과 모델

$$T_i = \begin{cases} 1: \text{실험 대상 } i \text{가 처치 받은 경우} \\ 0: \text{실험 대상 } i \text{가 처치 받지 않은 경우} \end{cases}$$

근본적인 문제

한 개체에 대해 $Y(0)$ 와 $Y(1)$ 중
단 하나만 관측할 수 있음.

보이지 않는 쪽 : '반사실'



인과 추론을 가능하게 하는 3가지 핵심 가정

01

일치성

"처치 T가 명확하게 정의되어야 함"
숨겨진 다른 형태의 처치가 없으며,
처치를 받은 개체의 결과는 잠재적
결과와 일치해야 한다.

02

상호 간섭 없음 (SUTVA)

"처치가 결과에 영향을 주지 않음"
한 실험 대상에 대한 처치 효과는 다
른 대상의 처치 여부와 무관해야 한
다. (파급 효과 X)

03

교환 가능성

"처치는 결과와 독립적이어야 함".
처치군과 대조군을 서로 맞바꾸어도
결과의 평균은 같아야 한다.

05

인과적 추정량

*개별 효과는 관측 불가능하므로, 통계적으로 추정 가능한 집단 평균 효과를 사용



ATE (Average Treatment Effect)

GENERAL POLICY

전체 인구에 대한 평균 처치 효과.

"모든 사람에게 약을 주었을 때와 아무에게도 안 주었을 때의 차이"

$$E[Y_1 - Y_0]$$



ATT (Average Treatment Effect on the Treated)

PROGRAM EVAL

실제 처치를 받은 집단에 나타난 효과.

"실제로 약을 먹은 사람들에게 나타난 효과는 얼마인가?"

$$E[Y_1 - Y_0 | T = 1]$$



CATE (Conditional Average Treatment Effect)

PERSONALIZATION

특정 조건(나이, 지역 등) 하에서의 평균 효과.

"20대 남성에게 이 약은 얼마나 효과적인가?" (개인화 마케팅 핵심)

$$E[Y_1 - Y_0 | X = x]$$

06

편향(Bias) - 인과추론을 어렵게 만드는 것

연관관계 = 인과효과 + 편향

선택 편향 (Selection Bias):

처치군(T=1)과 대조군(T=0)이 처치 전부터 이미 다른 특성을 가질 때 발생.

예: "약 복용자(처치군)가 비복용자보다 건강이 나쁘다"

→ 약 때문 x 원래 아픈 사람이 약을 먹었기 때문(선택 편향).

목표:

데이터 분석을 통해 이 편향을 제거하고 순수한 인과 효과만 남기는 것.

07

해결책 : 무작위 통제 실험(RCT)

핵심 원리

처치(T)를 무작위(Random)로 배정함.

효과

무작위 배정을 하면 처치군과 대조군이 통계적으로 동일해짐 .

결과

단순한 평균의 차이가 곧 인과 효과가 됨.

현실적 한계

비용, 윤리적 문제로 RCT가 불가능한 경우가 많음 → 관측 데이터 기반의 인과추론 기법들이 필요한 이유.

THANK YOU

-1부 1장 끝

소프트웨어학과 21학번 이준형