
Visual Instruction Tuning (LLaVA)

paper review

2026. 09. 21

이준형

목차

- Introduction
- **GPT-assisted Data Generation**
- **Architecture & Training**
- Experiments
- Conclusion

❖ Visual Instruction Tuning

2023년 NeurIPS에서 발표

현재 멀티모달 LLM(VLM) 분야에서 가장 많이 인용되는 대표 논문 중 하나

*Google Scholar 기준 16,984회 인용 (2026년 8월 기준)

GPT-4를 활용해 멀티모달 instruction-following 데이터를 생성하고, 이를 Vision-Language 모델 학습에 **최초로 적용**한 논문

Visual Instruction Tuning

Haotian Liu^{1*}, Chunyuan Li^{2*}, Qingyang Wu³, Yong Jae Lee¹

¹University of Wisconsin–Madison ²Microsoft Research ³Columbia University
<https://llava-vl.github.io>

Abstract


Instruction tuning large language models (LLMs) using machine-generated instruction-following data has been shown to improve zero-shot capabilities on new tasks, but the idea is less explored in the multimodal field. We present the first attempt to use language-only GPT-4 to generate multimodal language-image instruction-following data. By instruction tuning on such generated data, we introduce LLaVA: **L**arge **L**anguage and **V**ision **A**ssistant, an end-to-end trained large multimodal model that connects a vision encoder and an LLM for general-purpose visual and language understanding. To facilitate future research on visual instruction following, we construct two evaluation benchmarks with diverse and challenging application-oriented tasks. Our experiments show that LLaVA demonstrates impressive multimodal chat abilities, sometimes exhibiting the behaviors of multimodal GPT-4 on unseen images/instructions, and yields a 85.1% relative score compared with GPT-4 on a synthetic multimodal instruction-following dataset. When fine-tuned on Science QA, the synergy of LLaVA and GPT-4 achieves a new state-of-the-art accuracy of 92.53%. We make GPT-4 generated visual instruction tuning data, our model, and code publicly available.

Introduction

- Motivation

❖ 만약 인공지능(AI)이 이미지를 보고 자유롭게 대화할 수 있다면?

- 인간의 눈을 대체할 수 있는 시각 기능 (이미지 안에 무엇이 있는지)
- 시각 정보를 언어로 풀어내는 언어 능력 (자연스러운 대화 형태)
- 사용자의 다양한 지시를 유연하게 따르는 지시 이행 능력



이 “?”를 채우는 것이 *Visual Instruction Tuning*의 목표

Introduction

- Background

❖ 기존 비전 모델의 한계 vs LLM이 보여준 가능성

기존 비전 모델

- 분류 · 탐지 · 세그멘테이션 등 태스크별로 개별 학습
- 태스크 지시가 모델 설계에 암묵적으로 고정됨
- 사용자 지시에 유연하게 반응하지 못함



LLM (ChatGPT / GPT-4)

- 언어를 '범용 인터페이스'로 사용
- 다양한 태스크 지시를 언어로 명시적으로 표현 가능
- 하나의 모델이 여러 지시를 유연하게 수행

→ LLM의 instruction-following 능력을 이미지-언어 멀티모달 영역으로 확장하자

Introduction

- Contributions of this paper

❖ 이 논문의 4가지 핵심 기여

① Multimodal instruction data

GPT-4를 활용해 이미지-텍스트 쌍을 instruction 형식으로 변환하는 파이프라인 제안

② Large multimodal model (LLaVA)

CLIP 비전 인코더 + Vicuna LLM을 연결한 end-to-end 모델

③ LLaVA-Bench

다양하고 도전적인 태스크로 구성된 평가 벤치마크 2종 제안

④ 전면 오픈소스

데이터 · 코드 · 모델 체크포인트 · 데모 전체 공개

GPT-assisted Data Generation

- Motivation for data pipeline

❖ 가장 큰 문제: 비전-언어 instruction 데이터의 부재

- 이미지-텍스트 쌍(캡션) 데이터는 많지만, '지시-응답' 형태의 데이터는 거의 없음
- GPT-4/ChatGPT를 '데이터 생성기'로 활용하는 아이디어

이미지를 텍스트만 받는 GPT-4에게 어떻게 전달할까?

기호적 표현 1

Captions

장면을 다양한 관점에서 서술한 문장들

기호적 표현 2

Bounding Boxes

객체의 종류와 이미지 내 위치 좌표

Context type 1: Captions

A group of people standing outside of a black vehicle with various luggage.

Luggage surrounds a vehicle in an underground parking area


People try to fit all of their luggage in an SUV.

The sport utility vehicle is parked in the public garage, being packed for a trip

Some people with luggage near a van that is transporting it.

Context type 2: Boxes

person: [0.681, 0.242, 0.774, 0.694], backpack: [0.384, 0.696, 0.485, 0.914], suitcase: ...<omitted>



→ 이 두 가지를 텍스트로 GPT-4에 입력해 instruction 데이터를 자동 생성

GPT-assisted Data Generation

- Why text-only input

❖ 왜 이미지 대신 텍스트(Caption+Bounding Box)만으로 GPT-4에 전달했을까?

구조적 제약

- GPT-4/ChatGPT는 텍스트 전용 모델
→ 이미지를 직접 처리할 수 없음
- 이미지를 캡션("A black SUV surrounded by luggage")과 bounding box(좌표)로 "텍스트화"해서 우회 입력

비용 효율성

- 이미지 기반 데이터를 사람이 직접 라벨링하면 비용·시간이 크게 소요
- 기존 텍스트 캡션 데이터셋(COCO)을 재활용하면 대규모 데이터를 빠르고 저렴하게 증강 가능

→ GPT-4의 강력한 언어 추론 능력만으로도, 캡션·bbox 정보만 가지고 고품질 질문-응답 데이터 생성 가능



GPT-assisted Data Generation

- Three types of generated data

❖ 생성된 Instruction 데이터의 3가지 유형

대화형 (Conversation)

58K

이미지에 대한 자연스러운 Q&A.
객체 종류·개수·위치·상호작용 등에 대한 질의응답

상세 설명 (Detailed description)

23K

이미지를 풍부하고 포괄적으로 서술하는 응답

복합 추론 (Complex reasoning)

77K

단계적 논리 전개가 필요한 심층 질의응답

Response type 1: conversation

Question: What type of vehicle is featured in the image?
Answer: The image features a black sport utility vehicle (SUV) ...<omitted>

Response type 2: detailed description

The image is an underground parking area with a black sport utility vehicle (SUV) parked. There are three people in the scene, with one person standing closer to the left side of the vehicle, another person in the middle, and the third person on the right side. They are all working together to pack their luggage into the SUV for a trip. ...<omitted>

Response type 3: complex reasoning


Question: What challenges do these people face?
Answer: In the image, a group of people is standing outside a black SUV in a parking area, surrounded by various pieces of luggage, including suitcases and backpacks. They are facing the challenge of fitting all their luggage into the black SUV. There are multiple suitcases and backpacks to be packed, which suggests that the group has a significant amount of belongings ...<omitted>

총 158K개의 *language-image instruction* 샘플 (COCO 이미지 기반)

Architecture

- Step 1 — Vision encoding & projection

❖ 이미지를 언어모델이 이해할 수 있는 토큰으로 변환하는 과정



수식으로 표현하면

$H_v = W \cdot Z_v, \quad Z_v = \text{CLIP}(X_v)$

- Z_v : 이미지 X_v 를 CLIP으로 인코딩한 시각특징
- W : 학습 가능한 projection matrix (선형 변환)
- H_v : 언어모델의 word embedding과 같은 차원의 시각 토큰

설계 포인트

의도적으로 단순한 선형 레이어만 사용.
→ 빠른 데이터 중심 실험 반복 선택





Figure 1: LLaVA network architecture.

Architecture

- Step 2 — Language decoding

❖ 시각 토큰과 텍스트를 하나의 시퀀스로 결합해 응답을 생성하는 과정



왜 Vicuna인가?

- instruction-tuned LLM
 - 다양한 지시를 유연하게 따르는 능력이 사전에 이미 확보됨
- GPT 계열과 유사한 decoder-only 구조
 - 별도의 멀티모달 전용 구조 없이 기존 LLM을 거의 그대로 재사용

어떻게 결합하는가?


- H_v (비주얼 토큰)와 텍스트 토큰을 동일한 시퀀스 안에 함께 배치 (언어모델 입장에서 이미지는 '특수한 토큰들'일 뿐)
- 예: “이미지 설명: ” + H_v
→ 이어서 자연어 응답 X_a 를 auto-regressive하게 생성

언어 토큰과 비주얼 토큰을 같은 시퀀스로 처리 → 텍스트 생성뿐 아니라 질문-응답, 복합 추론까지 하나의 decoder로 통합 수행



Architecture

❖ LLaVA 전체 네트워크 구조



입력 시퀀스 형식 (multi-turn 대화)

```
 $X_{\text{system-message}}$  <STOP>
Human :  $X_{\text{instruct}}^1$  <STOP> Assistant:  $X_a^1$  <STOP>
Human :  $X_{\text{instruct}}^2$  <STOP> Assistant:  $X_a^2$  <STOP> ...
```

Training

❖ Stage 1: Feature Alignment 사전학습

- CC3M을 필터링한 595K개의 이미지-텍스트 쌍 사용
- 비전 인코더(CLIP) + LLM(Vicuna) 가중치는 모두 고정(freeze)
- 오직 Projection matrix (W)만 학습

의미: 고정된 LLM을 위한 '호환 가능한 시각 토큰라이저'를 학습하는 과정

학습 대상 파라미터

$\theta = W$ (projection matrix만)

고정(freeze)

- Vision Encoder (CLIP)
- Language Model (Vicuna)



Training

❖ Stage 2: End-to-End 파인튜닝

- 비전 인코더는 계속 고정, Projection + LLM 전체를 함께 업데이트

$$p(\mathbf{X}_a | \mathbf{X}_v, \mathbf{X}_{\text{instruct}}) = \prod_{i=1}^L p_{\theta}(\mathbf{x}_i | \mathbf{X}_v, \mathbf{X}_{\text{instruct}, < i}, \mathbf{X}_{a, < i}),$$

$\theta = \{ W, \varphi_{\text{LLM}} \}$ (projection + LLM 전체)

φ_{LLM} : Vicuna LLM 파라미터

멀티모달 챗봇

158K instruction 데이터 전체로 파인튜닝. 대화형은 multi-turn, 나머지 두 유형은 single-turn

ScienceQA

이미지+텍스트 맥락이 주어진 객관식 과학 문제. 추론 과정과 정답을 함께 생성하도록 학습

전체 목적함수: 자기회귀적(auto-regressive) 다음 토큰 예측, 정답 토큰에 대해서만 loss 계산


Experiments

- LLaVA-Bench evaluation

❖ 정량 평가: GPT-4를 심판으로 활용한 상대 점수

- 텍스트만 보는 GPT-4의 답변을 이론적 상한선으로 삼아 상대 점수 산출

	Conversation	Detail description	Complex reasoning	All
Full data	83.1	75.3	96.5	85.1
Detail + Complex	81.5 (-1.6)	73.3 (-2.0)	90.8 (-5.7)	81.9 (-3.2)
Conv + 5% Detail + 10% Complex	81.0 (-2.1)	68.4 (-7.1)	91.5 (-5.0)	80.5 (-4.4)
Conversation	76.5 (-6.6)	59.8 (-16.2)	84.9 (-12.4)	73.8 (-11.3)
No Instruction Tuning	22.0 (-61.1)	24.0 (-51.3)	18.5 (-78.0)	21.5 (-63.6)



~80K개의 적은 이미지로 학습했음에도 GPT-4와 유사한 수준의 심층 이미지 이해를 보임. 다만 '패치 뭉치'로 인식해 세밀한 의미를 놓치는 한계도 관찰됨.




Experiments

- ScienceQA benchmark

❖ ScienceQA: 21K개 멀티모달 객관식 과학 문제

- GPT-4를 '심판'으로 결합(judge scheme)해 두 모델의 답이 다를 때 최종 판단



Ablation 핵심: (i) 마지막 이전 레이어 특징 사용이 더 좋음 (ii) 정답 먼저 예측이 근소 우위 (iii) Stage 1 생략 시 정확도 5.11%p 급락 (iv) 모델 클수록(7B→13B) 향상

Conclusion

❖ 결론

- Visual Instruction Tuning: GPT-4로 생성한 데이터로 이미지-언어 instruction-following 모델을 학습하는 접근
- 단순한 아키텍처(선형 projection)로도 사전학습된 컴포넌트를 잘 연결하면 강력한 성능이 나온다는 실증
- ScienceQA SoTA 달성(92.53%), LLaVA-Bench에서 GPT-4에 근접한 심층 이미지 이해 능력 입증

다음 논문(VGGT, SpatialStack)과의 연계점

- LLaVA는 CLIP의 2D 이미지 특징을 단순 선형 projection으로 언어모델에 연결 — 이미지를 "패치 토큰"로 다뤄 3D 공간 구조·기하학적 관계는 명시적으로 포착하지 못함
- 이 한계는 "이미지를 넘어 실제 3D 공간을 이해하는 VLM을 만들려면 무엇이 필요한가?"라는 질문으로 이어짐
- 다음으로 살펴볼 VGGT(3D 기하 구조를 추정하는 geometry foundation model)와 SpatialStack(VGGT의 geometry feature를 VLM에 층별로 융합)은, 바로 이 "공간적 맥락 이해 부족"을 정면으로 다루는 후속 연구 흐름

Q&A

상명대학교 소프트웨어학과 이준형
leejunhyeong02@gmail.com
010-3205-3276