
SpatialStack

Layered Geometry-Language Fusion for 3D VLM Spatial Reasoning

paper review

2026. 09. 21

이준형

목차

- Introduction
- Why Multi-level Geometry Features?
- Architecture: Geometry-Language Fusion
- Experiments
- Conclusion

SpatialStack: Layered Geometry-Language Fusion for 3D VLM Spatial Reasoning

Jian Zhang^{1*} Shijie Zhou^{2,3*} Bangya Liu^{4*} Achuta Kadambi² Zhiwen Fan⁵

¹XMU ²UCLA ³Google ⁴UW-Madison ⁵TAMU

<https://spatial-stack.github.io/>




Figure 1. **SpatialStack: Layered Geometry-Language Fusion.** Conventional VLMs (a) fuse only a single deep geometry feature with vision tokens, which limits both fine-grained spatial understanding and high-level spatial reasoning. SpatialStack (b) instead stacks multi-level geometry features and injects them hierarchically into successive LLM decoder layers, yielding stronger 3D spatial understanding across benchmarks.


- 2026년 CVPR에 게재 (XMU, UCLA, Google, UW-Madison, TAMU 공동 연구)
- VGGT를 geometry encoder로 활용해 VLM의 3D 공간 추론 능력을 강화하는 계층적 융합 프레임워크
- 기존 연구들이 “가장 깊은 층 하나만” 융합하던 한계를 지적하고, 여러 층을 LLM decoder에 계층적으로 주입
- LLaVA(vision+LLM 결합)의 구조를 계승하면서, VGGT라는 3D geometry encoder를 추가로 결합한 확장판으로 볼 수 있음

Introduction

- Motivation

❖ 기존 VLM들이 3D 공간 추론에 약한 이유

- 대형 VLM들은 3D geometry·공간 관계를 제대로 인코딩하지 못함
- 최근 연구들이 geometry transformer(VGGT 등)를 VLM에 결합하기 시작했지만, 공통적으로 가장 깊은 층(deep layer)의 feature 하나만 융합
- 그러나 geometry encoder는 DPT 구조 기반 — 원래 여러 층에서 정보를 뽑아 쓰도록 설계됨, 마지막 층만 쓰면 중간층의 풍부한 계층적 신호를 버리게 됨



기존 방식
deep layer feature만 융합



한계
세밀한 지역 정보 손실



결과
공간 추론 병목 현상 발생

Introduction

- Related Work

❖ 기존 VLM·geometry 융합 연구들과의 비교

- 일반 MLLM 계열(LLaVA, Qwen2.5-VL 등): vision encoder + LLM을 단순 projection layer로 연결 — geometry 정보 자체가 없음, final-layer 시각 특징만 융합

Method	Geometry 융합 방식	한계
Spatial-MLLM	Dual-encoder 구조	final-layer만 융합
VG-LLM	Patch-level 융합	final-layer만 융합
VLM-3R	Cross-attention 방식	final-layer만 융합
SSR	Rationale-guided 융합	final-layer만 융합

공통점: 이 연구들 모두 geometry/vision encoder의 "마지막 층" feature만 사용 → SpatialStack이 직접 지적하는 지점

Introduction

- Contributions of this paper

❖ 이 논문의 3가지 핵심 기여

①

Layer-wise 분석 최초 시도

vision·geometry encoder와 LLM decoder 간 융합 깊이가 공간추론 세분화에 미치는 영향을 체계적으로 규명

②

SpatialStack 프레임워크

여러 층의 geometry feature를 LLM decoder에 계층적으로 정렬·주입 — 기존 단일 심층 융합을 넘어서는 설계

③

VLM-SpatialStack 구현

Qwen 계열 기반 구체화, 여러 3D 벤치마크에서 SOTA 및 강한 일반화 성능 입증

Why Multi-level Geometry Features?

- Qualitative Analysis

❖ 왜 deep layer feature 하나만으로는 부족한가

- 한 시점의 이미지를 VGGT에 넣고, 서로 다른 층의 patch token을 원래 H×W 격자 형태로 다시 펼쳐 시각화
- 특정 영역(ROI)과 다른 모든 위치 간의 유사도를 계산 — 밝을수록 유사, 어두울수록 비사하지 않음


Shallow Layer

- 경계가 뚜렷하고 선명함, 지역 구조가 잘 보존됨
- → 세밀한 저수준(low-level) 공간 지각에 유리


Deep Layer

- 활성화가 균일해져 물리적으로 다른 영역도 비슷해 보임(세밀 구조 손실)
- → 대신 전역적/의미적 맥락을 압축 → 고수준(high-level) 추론에 유리


Shallow Layer



Middle Layer



Deep Layer



shallow·deep feature가 서로 다른 역할 → '여러 층을 동시에 활용하자'는 SpatialStack의 출발점

Why Multi-level Geometry Features?


- Quantitative Analysis

❖ 레이어별 주입 실험 (Table 1) + 그래프로 본 경향 (Figure 4)

Model	Low-Level Avg	High-Level Avg	Overall
Qwen3.5 (fine-tuned)	61.37	64.76	63.07
Single-layer (geo enc: 11)	66.11	64.48	65.30
Single-layer (geo enc: 17)	63.89	65.76	64.83
Single-layer (geo enc: 23)	64.33	66.36	65.35
Multi-Layer Fusion	64.69	65.15	64.92

Table 1. Ablation Results on Geometry Token Fusion Depth.

- 의외로, 여러 층을 그냥 합치는 Multi-Layer Fusion(64.92)이 가장 좋은 단일 층 L23(65.35)보다도 낮음
- 이 관찰이 바로 SpatialStack 설계의 직접적 동기



왜 단순 합산은 실패할까?


- 얇은 층(국소적 구조)과 깊은 층(전역적 의미)은 서로 다른 종류의 정보를 담고 있어, 그대로 더하면 두 신호가 서로 간섭·상쇄될 수 있음
- Figure 4에서 보듯 low-level과 high-level의 최적 깊이 자체가 다름 → 하나의 결합 방식으로 '평균'을 내면 어느 쪽에도 최적화되지 않음

Low-level은 L11에서 정점 후 하락, High-level은 깊을수록 꾸준히 상승 — 서로 다른 최적 깊이를 가짐


Architecture

- Full pipeline

❖ SpatialStack 전체 구조




Vision path



Geometry path



↓↓↓ (각 층별 additive residual로 주입)



Architecture

- Geometry Encoder

❖ Geometry Encoder = VGGT (Frozen)

- VGGT를 3D 속성 예측 모델이 아닌 “특징 추출기”로 재해석 — DPT head 대신 중간 hidden state만 추출
- VGGT 내부 24개 레이어 중, 세 개의 지점(L11 / L17 / L23)을 선택해 geometry feature로 활용
- VGGT 자체 DPT가 쓰던 4개 지점(4/11/17/23) 중, 가장 얇은 4번만 제외 (예비 실험에서 성능이 낮았기 때문)
- 왜 DPT head 대신 hidden state인가? DPT head는 depth·point map 등 특정 예측 task에 맞춰 압축된 출력 — 범용성이 떨어짐. hidden state는 task-specific하게 좁혀지기 전 단계라 VLM에 재사용하기 더 유연함

VGGT — 24개 Alternating-Attention 레이어 (frozen)

L11

L17

L23

Eq. (3) — VGGT 내부 L개 레이어를 통과한 최종 표현

$$\mathbf{Z}_L = f_L^{\text{geo}} \left(f_{L-1}^{\text{geo}} \left(\cdots f_1^{\text{geo}} \left([\mathbf{Z}_0^{(1)}; \cdots; \mathbf{Z}_0^{(K)}] \right) \right) \right)$$

Architecture

- Geometry-Language Fusion

❖ 계층적 주입: Geometry layer ↔ LLM decoder layer 대응

Eq. (4) — Geometry token merger

$$\mathbf{G}_{l_i} = \mathcal{M}_{\text{geo}}^{(l_i)}(\mathbf{Z}_{l_i}), \quad \mathbf{G}_{l_i} \in \mathbb{R}^{N' \times D_{\text{lang}}}.$$

Eq. (5) — LLM decoder layer j에 additive residual로 주입

$$\mathbf{H}^{(j)'} = \mathbf{H}^{(j)} + \mathbf{G}_{l_j}, \quad j \in \{0, 1, 2\}.$$

Geometry Layer	LLM Decoder Layer	대응 의미
L11 (shallow)	L0	세밀한 저수준 정보 → 언어모델 초반에 주입
L17 (middle)	L1	중간 수준 맥락 → 언어모델 중반에 주입
L23 (deep)	L2	전역적 의미 맥락 → 언어모델 후반에 주입

왜 concat이나 cross-attention이 아니라 masked additive fusion인가?

- LLM decoder 구조 자체는 그대로 유지하면서 값만 더하는 방식이라 추가 파라미터·연산 오버헤드가 거의 없음
- vision-token이 위치한 자리에만 정확히 더해지므로, text-token 경로(언어 능력)는 건드리지 않고 geometry 정보만 선택적으로 주입 가능

Masked additive fusion: geometry feature는 vision-token이 위치한 자리에만 더해짐 (text token에는 영향 없음)

Architecture

- Implementation Details (Appendix A)

❖ Geometry token을 vision token과 어떻게 정렬하는가

- Token Structuring: VGGT 각 레이어 출력은 camera token 1개 + register token 4개 + patch token들로 구성 — fusion 전 camera/register token은 제거하고 patch token만 사용
- Windowing/Reordering: patch token을 vision encoder의 병합 토큰과 spatial하게 맞추기 위해, $s \times s$ (기본 $s=2$) 윈도우 단위로 재정렬 — 인접한 4개 geometry token이 병합된 1개 vision token과 대응
- Geometry-to-Language Projection: RMSNorm으로 정규화 → 윈도우 단위 병합 → linear projection으로 언어모델 차원 (Dlang)에 맞춤

핵심: geometry token과 vision token의 "공간적 위치"를 정확히 맞춰야 masked additive fusion이 올바른 위치에 정보를 더할 수 있음

Experiments

- Cross-benchmark comparison

❖ 주요 벤치마크 성능 비교 (Table 2)

Methods	VSI-Bench	SPAR-Bench	BLINK-Spatial	CV-Bench	Overall
Qwen3.5 (fine-tuned)	64.76	68.75	56.10	84.49	68.52
GVF-L23 (VG-LLM [60])	66.36	70.83	51.91	84.64	68.43
GVF-L11/17/23	65.15	71.20	51.28	84.33	67.99
SpatialStack	67.52	71.39	52.12	85.53	69.14

유일한 예외 — BLINK-Spatial

- SpatialStack이 유일하게 못 이긴 항목: BLINK-Spatial (52.12 vs Qwen3.5 baseline 56.10)
- (추정) BLINK-Spatial은 단일 이미지의 저수준 지각 위주 벤치마크 — geometry 정보 주입이 오히려 미세한 원본 vision feature를 살짝 교란했을 가능성

단일 층(GVF-L23)이나 단순 다층 결합(GVF-L11/17/23) 모두보다 SpatialStack이 종합 최고 성능


Experiments

- VSI-Bench Detailed Breakdown

❖ VSI-Bench 세부 태스크별 성능 (Table 3)

- Rank 컬럼: SpatialStack-5B는 오픈소스·프로프라이어터리 모델을 통틀어 종합 1위 (Gemini-2.5 Pro 포함)
- 레이더 차트에서 특히 Route Plan · Relative Direction처럼 여러 시점을 종합해야 하는 축에서 격차가 두드러짐 — high-level reasoning 우위를 시각적으로 재확인

Methods	Rank	Avg.	Obj. Count	Abs. Dist.	Obj. Size	Room Size	Rel. Dist.	Rel. Dir.	Route Plan	Appr. Order
			Numerical Answer				Multiple-Choice Answer			
Baseline										
Chance Level (Random)	-	-	-	-	-	-	25.0	36.1	28.3	25.0
Chance Level (Frequency)	-	34.0	62.1	32.0	29.9	33.1	25.1	47.9	28.4	25.2
Proprietary Models (API)										
GPT-4o	2	34.0	46.2	5.3	43.8	38.2	37.0	41.3	31.5	28.5
Gemini-2.5 Pro	1	51.5	43.8	34.9	64.3	42.8	61.1	47.8	45.9	71.3
Open-source Models										
LongVILA-8B	15	21.6	29.1	9.1	16.7	0.0	29.6	30.7	32.5	25.5
Qwen2.5-VL-3B	14	28.7	33.1	19.4	17.4	24.8	37.3	44.3	31.4	22.0
VILA-1.5-8B	13	28.9	17.4	21.8	50.3	18.8	32.1	34.8	31.0	24.8
LongVA-7B	12	29.2	38.0	16.6	38.9	22.2	33.1	43.3	25.4	15.7
VILA-1.5-40B	11	31.2	22.4	24.8	48.7	22.7	40.5	25.7	31.5	32.9
LLaVA-OneVision-7B	10	32.4	47.7	20.2	47.4	12.3	42.5	35.2	29.4	24.4
LLaVA-Video-7B	9	35.6	48.5	14.0	47.8	24.2	43.5	42.4	34.0	30.6
LLaVA-OneVision-72B	8	40.2	43.5	23.9	57.6	37.5	42.5	39.9	32.5	44.6
LLaVA-Video-72B	7	40.9	48.9	22.8	57.4	35.3	42.4	36.7	35.0	48.6
Spatial-MLLM-4B	6	47.0	65.3	34.8	63.1	45.1	41.3	46.2	33.5	46.3
VG-LLM-4B	5	47.3	66.0	37.8	55.2	59.2	44.6	45.6	33.5	36.4
Qwen3.5-4B	4	53.6	56.5	36.5	67.5	53.8	60.3	57.5	34.0	62.3
Cambrian-S-3B	3	57.3	70.7	40.6	68.0	46.3	64.8	61.9	27.3	78.8
SpatialStack-4B (Qwen2.5)	2	60.9	69.2	45.4	63.0	63.2	57.9	68.4	40.2	79.6
SpatialStack-5B (Qwen3.5)	1	67.5	71.0	55.6	69.1	68.2	67.3	84.1	41.2	83.5



Experiments

- CV-Bench Detailed Comparison

❖ CV-Bench 2D/3D 성능 비교 (Table 4)

- Qwen2.5 기반 SpatialStack-4B가 기본 모델 및 VG-LLM, Cambrian-S 대비 우수
- Qwen3.5로 확장한 SpatialStack-5B는 3D(92.2%)·평균(85.5%) 모두 SOTA 갱신
- Dual-Encoder 계열(VG-LLM)과 비교해도 3D에서 격차가 뚜렷(92.2 vs 87.7) — geometry encoder를 얹게 한 번만 결합하는 것만으론 부족함을 시사

Model	2D (%)	3D (%)	Avg. (%)
Proprietary Models (API)			
GPT-4o [19]	74.8	83.0	78.9
Open-source Models			
Mini-Gemini-HD-34B [27]	71.5	79.2	75.4
LLaVA-NeXT-34B [24]	73.0	74.8	73.9
Cambrian-1-34B [45]	74.0	79.7	76.9
SAT-LLaVA-Video-7B [40]	73.0	83.8	78.4
SPAR-8B [56]	72.3	89.1	80.7
Qwen2.5-VL-3B [2]	67.9	70.4	69.2
Qwen3.5-4B [43]	79.7	90.2	85.0
Cambrian-S-3B [53]	76.1	76.3	76.2
Dual-Encoder MLLMs			
VG-LLM-4B [60]	71.3	87.7	79.5
SpatialStack-4B (Qwen2.5)	75.4	87.0	81.2
SpatialStack-5B (Qwen3.5)	78.9	92.2	85.5

Experiments

- General Capability (Table 5)

❖ 공간추론에 특화되면서, 일반 능력은 잃지 않았는가 (Table 5)

Method	MMBench	Video-MME	BLINK	Temp Compass	Overall
Qwen3.5-4B	83.25	62.44	61.12	66.84	68.41
SpatialStack-5B (Qwen3.5)	83.42	63.74	55.46	69.37	68.00

- 일반 멀티모달 이해(MMBench), 비디오 이해(Video-MME), 시공간 추론(TempCompass)에서 baseline과 거의 동등하거나 더 우수
- BLINK(세밀 시각지각)에서 소폭 하락이 있지만, Overall 기준 baseline과 거의 차이 없음(68.41 vs 68.00)
- 가능한 이유: VGGT는 frozen 상태로 추가 연결만 됐을 뿐, LLM 자체의 언어 능력에는 거의 개입하지 않기 때문으로 해석됨

공간추론 능력을 강화하면서도 일반 능력의 catastrophic forgetting이 없음을 확인

Experiments

- Ablation: Layer Selection (Table 6)

❖ 정확한 레이어 번호가 중요한가, 깊이 구간이 중요한가 (Table 6)

Metric	L21	L22	L23	+L21	+L22	+L23
Low-Level	63.54	64.87	64.33	65.89	65.45	64.44
High-Level	65.57	66.51	66.36	65.95	66.78	67.52

- L23을 L21이나 L22로 바꿔도(단독 또는 L11/L17과의 조합), 성능 차이가 거의 없음
- 실무적 의미: 정확한 레이어 번호를 그리드서치할 필요 없이, shallow/mid/deep 각 구간에서 대표 레이어 하나씩만 고르면 충분 — 하이퍼파라미터 탐색 비용 절감

결론: 정확한 레이어 번호보다, shallow~mid~deep 구간을 고르게 커버하는 것 자체가 중요 (broad sampling > specific index)

Experiments

- Ablation: Fusion Order (Table 7)

❖ 계층적 정렬 순서가 정말 중요한가 (Table 7)

Methods	VSI Bench	SPAR Bench	BLINK Spatial	CV Bench	Overall
Qwen3.5	64.76	68.75	56.10	84.49	68.52
Vision Fusion	64.27	69.68	56.45	83.11	68.38
SpatialStack (Reverse)	67.22	71.97	50.08	84.82	68.52
SpatialStack (final)	67.52	71.39	52.12	85.53	69.14

- SpatialStack(final): Geo-L11→LLM-L0, Geo-L17→LLM-L1, Geo-L23→LLM-L2 (shallow→shallow, deep→deep)
- SpatialStack(Reverse): 순서를 뒤집음(Geo-L11→LLM-L2, ..., Geo-L23→LLM-L0)
- 실무적 의미: 구현 시 대응 순서를 임의로 바꾸면 성능 손실(Reverse는 BLINK-Spatial에서 특히 -2.04%p) — shallow↔shallow, deep↔deep 매칭을 반드시 지켜야 함

정방향(final)이 Reverse·Vision Fusion보다 우수 → 얇은 층은 얇은 층에, 깊은 층은 깊은 층에 대응시키는 계층적 정렬 자체가 핵심

Conclusion

❖ 결론

- shallow layer는 세밀한 저수준 지각, deep layer는 전역적 맥락 — 계층적 대응관계를 규명
- naive한 다층 융합은 feature interference를 유발 — 융합 위치와 방식(순서)이 핵심 과제
- VGGT의 다층 표현을 LLM decoder에 계층적으로 주입 → 여러 3D 공간추론 벤치마크에서 SOTA, 일반 능력도 유지

VGGT와의 연계점

- VGGT는 3D 속성(camera/depth/point map/tracking)을 직접 예측하는 24층 feed-forward transformer
- SpatialStack은 VGGT의 예측 head(DPT)는 버리고, 내부 24층 중 3개 지점(L11/17/23)의 hidden state만 “geometry feature 추출기”로 재활용
- VGGT가 검증한 “멀티태스크 학습이 3D 이해를 돕는다”는 통찰을, SpatialStack은 “멀티레이어가 spatial reasoning의 서로 다른 수준을 돕는다”는 통찰로 확장

Q&A

상명대학교 소프트웨어학과 이준형

leejunhyeong02@gmail.com

010-3205-3276